Laboratorio evolutivo 03

Cómputo y orquestación: de servidores a capacidad administrada

Computación en Nube · EAFIT · Sesión 06 · 25 de agosto de 2026

Duración	Modalidad	Entorno	Carácter
90–105 minutos	Equipos de 4	AWS Academy Learner Lab	Formativo; prepara la evolución posterior

1. Propósito y resultado

Evolucionar el baseline cerrado de S05 desde servidores accesibles individualmente hacia una capacidad HTTP presentada mediante un único endpoint. El equipo incorporará un Application Load Balancer, Target Group, Launch Template y Auto Scaling Group para observar distribución de tráfico, estado de salud de targets y recuperación de capacidad deseada como comportamientos relacionados pero distintos.

Pregunta rectora: ¿Cómo convertimos dos servidores independientes en capacidad accesible mediante un único endpoint, capaz de excluir targets no saludables y recuperar automáticamente la capacidad deseada?

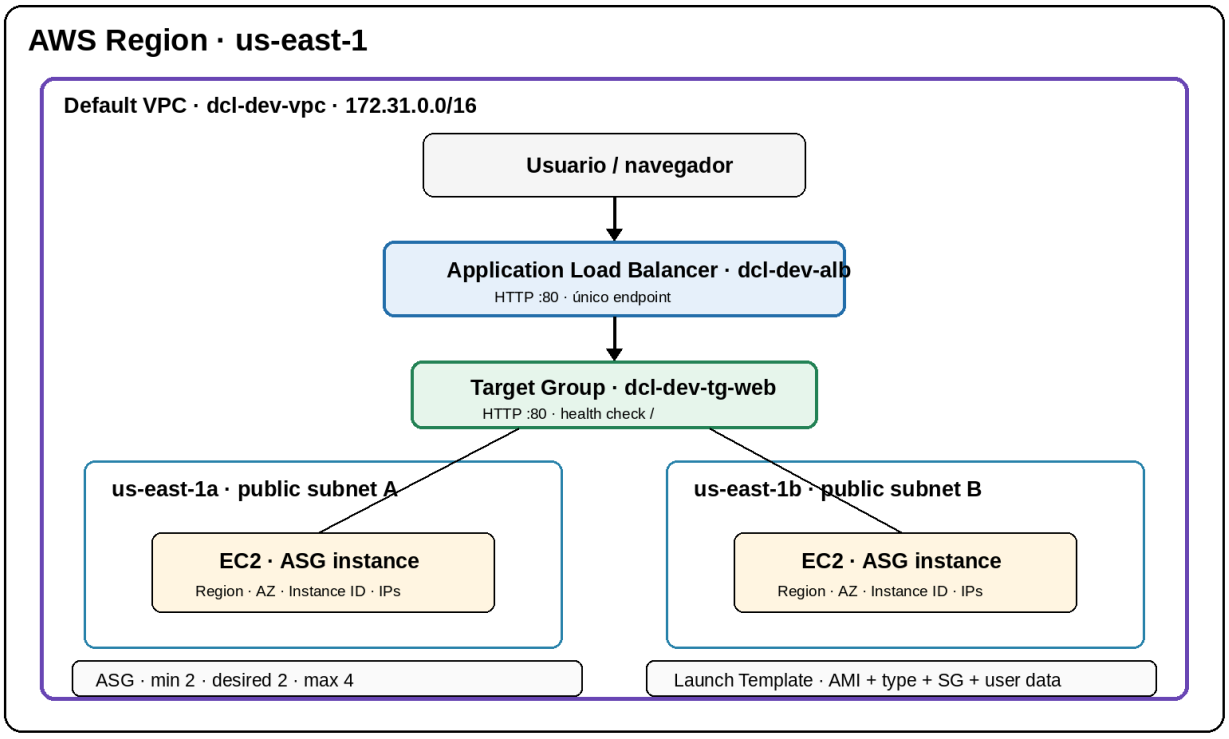


Figura 1. Arquitectura de la iteración 03. Las subnets privadas del baseline se conservan, pero no se utilizan para el cómputo de esta práctica.

OJO TÉCNICO. Health check / exclusión de tráfico y reemplazo de capacidad por Auto Scaling no son el mismo mecanismo. La práctica los observará por separado.

Objetivos de aprendizaje

- Presentar varias instancias mediante un único endpoint HTTP.
- Relacionar Target Group y health checks con elegibilidad para recibir tráfico.
- Usar una configuración repetible para crear nueva capacidad.
- Explicar min / desired / max como estado de capacidad administrada.
- Distinguir exclusión de un target no saludable de reemplazo de capacidad del Auto Scaling Group.

2. Baseline, recursos y convenciones

La práctica sigue la secuencia: descubrir → verificar → reutilizar → extender → validar. No reconstruya la red.

- Región: us-east-1.
- Default VPC dcl-dev-vpc · 172.31.0.0/16.
- dcl-dev-subnet-public-a en us-east-1a y dcl-dev-subnet-public-b en us-east-1b.
- dcl-dev-subnet-private-a 172.31.96.0/24 y dcl-dev-subnet-private-b 172.31.97.0/24: conservar, no usar para el cómputo de esta iteración.
- Internet Gateway y routing público existentes.
- Si dcl-dev-web-a / dcl-dev-web-b ya no existen por cleanup de S05, no las recree para reproducir el estado anterior.

Tipo	Recurso	Nombre / configuración
Reutilizar	VPC	dcl-dev-vpc · Default VPC
Reutilizar	Subnets públicas	dcl-dev-subnet-public-a / dcl-dev-subnet-public-b
Conservar	Subnets privadas	dcl-dev-subnet-private-a / dcl-dev-subnet-private-b
Verificar / recrear si falta	SG web	dcl-dev-sg-web
Crear	SG ALB	dcl-dev-sg-alb
Crear	Target Group	dcl-dev-tg-web · HTTP :80
Crear	ALB	dcl-dev-alb · internet-facing
Crear	Launch Template	dcl-dev-lt-web
Crear	Auto Scaling Group	dcl-dev-asg-web · min 2 · desired 2 · max 4

Etiquetas estándar: dcl:project=digital-cafe-luna, dcl:environment=dev, dcl:owner-team=team-XX y dcl:managed-by=console.

3. Paso a paso en la consola

Fase 0 — Descubrir y verificar el baseline

Qué hacemos: Confirmar la infraestructura persistente de S05 y detectar qué recursos temporales ya no existen.

Por qué: La evolución debe partir del estado real, no de recrear recursos solo para imitar una sesión anterior.

1. Confirme us-east-1 y localice dcl-dev-vpc.

2. Verifique las subnets públicas A/B y que su routing conserva 0.0.0.0/0 hacia dcl-dev-igw.

3. Verifique que las subnets privadas y dcl-dev-rt-private siguen presentes; no las modifique.

4. Compruebe si dcl-dev-sg-web existe. Si fue eliminado en S05, créelo nuevamente sin SSH; por ahora puede quedar sin regla HTTP hasta crear el SG del ALB.

5. Compruebe si las EC2 independientes de S05 existen. Si no existen, continúe: no las recree.

Checkpoint: La red está disponible y estamos listos para extender cómputo, salud y capacidad.

Fase 1 — Crear los Security Groups mínimos

1. Cree dcl-dev-sg-alb en dcl-dev-vpc. Inbound: HTTP TCP/80 desde 0.0.0.0/0. Sin SSH.

2. En dcl-dev-sg-web, configure inbound HTTP TCP/80 con source = dcl-dev-sg-alb. No exponga HTTP directamente a Internet y no agregue SSH.

3. Conserve la salida predeterminada para permitir el bootstrap mediante user data.

Validación: El ALB puede recibir HTTP desde Internet y las instancias web solo aceptan HTTP originado desde el SG del ALB.

Fase 2 — Crear el Target Group y el ALB

1. Cree dcl-dev-tg-web con Target type = Instances, Protocol = HTTP, Port = 80 y VPC = dcl-dev-vpc.

2. Configure Health check protocol = HTTP, path = /, port = traffic port, interval = 10 s, healthy threshold = 2, unhealthy threshold = 2 y success codes = 200.

3. No registre manualmente instancias si las EC2 heredadas ya no existen. Si siguen presentes, su registro puede utilizarse como observación opcional de continuidad, pero no es requisito.

4. Cree dcl-dev-alb como Application Load Balancer internet-facing en dcl-dev-subnet-public-a y dcl-dev-subnet-public-b.

5. Asocie dcl-dev-sg-alb y cree listener HTTP/80 con acción Forward to dcl-dev-tg-web.

Validación: El ALB queda Active y presenta un DNS público. Todavía puede responder 503 mientras el Target Group no tenga targets saludables.

Fase 3 — Crear capacidad repetible con Launch Template

El Launch Template define cómo nace cada unidad de capacidad. Use Amazon Linux 2023 disponible en el Learner Lab y un instance type pequeño permitido por Academy. No fije un AMI ID histórico.

1. Name: dcl-dev-lt-web.

2. Key pair: no crear ni seleccionar; no utilizaremos SSH.

3. Security group: dcl-dev-sg-web.

4. Metadata version / IMDS: V2 only (IMDSv2 requerido).

5. No seleccione una subnet en el Launch Template; las subnets se definirán en el Auto Scaling Group.

6. Pegue el siguiente user data.

```
#!/bin/bash
dnf install -y httpd
systemctl enable --now httpd

TOKEN=$(curl -sS -X PUT -H "X-aws-ec2-metadata-token-ttl-seconds: 21600" http://169.254.169.254/latest/api/token)
REGION=$(curl -sS -H "X-aws-ec2-metadata-token: $TOKEN" http://169.254.169.254/latest/meta-data/placement/region)
AZ=$(curl -sS -H "X-aws-ec2-metadata-token: $TOKEN" http://169.254.169.254/latest/meta-data/placement/availability-zone)
INSTANCE_ID=$(curl -sS -H "X-aws-ec2-metadata-token: $TOKEN" http://169.254.169.254/latest/meta-data/instance-id)
PRIVATE_IP=$(curl -sS -H "X-aws-ec2-metadata-token: $TOKEN" http://169.254.169.254/latest/meta-data/local-ipv4)
PUBLIC_IP=$(curl -fsS -H "X-aws-ec2-metadata-token: $TOKEN" http://169.254.169.254/latest/meta-data/public-ipv4 || true)
[ -z "$PUBLIC_IP" ] && PUBLIC_IP="Not assigned"

cat > /var/www/html/index.html <<EOF
<html><body>
<h1>Digital Cafe Luna</h1>
<p>Region: $REGION</p>
<p>Availability Zone: $AZ</p>
<p>Instance ID: $INSTANCE_ID</p>
<p>Private IP: $PRIVATE_IP</p>
<p>Public IP: $PUBLIC_IP</p>
</body></html>
EOF
```

Cada instancia nueva ejecutará este mismo script y publicará automáticamente su propia identidad; la página no contiene valores hardcoded.

Fase 4 — Crear el Auto Scaling Group

1. Cree dcl-dev-asg-web a partir de dcl-dev-lt-web.

2. VPC: dcl-dev-vpc. Seleccione dcl-dev-subnet-public-a y dcl-dev-subnet-public-b.

3. Attach to an existing load balancer / Target Group: dcl-dev-tg-web.

4. Capacity: min = 2, desired = 2, max = 4.

5. Health checks: conserve Amazon EC2 health checks. No habilite Elastic Load Balancing health checks como fuente adicional de reemplazo durante este laboratorio.

6. No configure scaling policy obligatoria. El objetivo es observar capacidad deseada y reemplazo, no estudiar políticas avanzadas.

Validación: Espere dos instancias InService y dos targets healthy. Registre Instance ID y AZ de ambas.

Fase 5 — Prueba de distribución: un solo endpoint

1. Copie el DNS de dcl-dev-alb y abra http://DNS-DEL-ALB.

2. Refresque varias veces. Si el navegador reutiliza contenido, use una ventana privada o agregue un parámetro cambiante, por ejemplo ?v=1, ?v=2.

3. Registre al menos dos respuestas diferentes y compare Region, AZ, Instance ID, Private IP y Public IP.

Resultado esperado: El usuario utiliza un solo endpoint y observa más de una instancia detrás del ALB. El balanceador distribuye capacidad existente; no crea capacidad.

Fase 6 — Prueba A: Health y exclusión de tráfico

Objetivo: hacer que una aplicación deje temporalmente de responder mientras la instancia EC2 permanece en estado Running, y observar Target Group + ALB.

1. Confirme que existen dos targets healthy.

2. Seleccione una instancia perteneciente al ASG y ejecute Instance state > Reboot instance.

3. Observe EC2: el estado de la instancia permanece Running durante el reboot. Los status checks EC2 pueden verse temporalmente afectados.

4. Observe Target Groups > dcl-dev-tg-web > Targets hasta que el target afectado falle los health checks y, si la ventana de tiempo lo permite, aparezca unhealthy.

5. Mientras exista otro target healthy, refresque el DNS del ALB y registre qué Instance ID continúa atendiendo nuevas solicitudes.

6. Observe también el comportamiento del Auto Scaling Group y regístrelo como evidencia adicional. No predetermine si conservará o reemplazará esa instancia, porque los status checks EC2 pueden cambiar temporalmente durante el reboot.

7. Espere la recuperación de la aplicación y registre si el target vuelve a healthy.

OJO TÉCNICO. No reinicie simultáneamente todos los targets. Si todos quedan unhealthy, Application Load Balancer puede operar en fail-open y enrutar tráfico a targets no saludables.

Aprendizaje: El Target Group determina qué destinos son elegibles para nuevas solicitudes; el health check no debe confundirse con la demostración determinista de recuperación de desired capacity.

Fase 7 — Prueba B: recuperación determinista de capacidad

1. Confirme dcl-dev-asg-web con desired = 2 y dos instancias InService.

2. Seleccione una instancia perteneciente al ASG y ejecute Instance state > Terminate instance.

3. Observe cómo la capacidad real cae temporalmente por debajo de desired.

4. Observe el lanzamiento de una nueva instancia hasta recuperar desired = 2.

5. En el Target Group, espere que la nueva instancia se registre y alcance healthy.

6. Refresque el DNS del ALB y confirme que la nueva Instance ID aparece atendiendo tráfico.

Resultado esperado: La pérdida de una unidad de capacidad es seguida por un reemplazo hasta recuperar la capacidad deseada del grupo.

4. Verificación con AWS CLI

Los comandos son de verificación. Ejecútelos en CloudShell si está disponible; si AWS Academy restringe CloudShell, realice las mismas comprobaciones desde la consola y registre la limitación.

```
# ALB y DNS
aws elbv2 describe-load-balancers \
  --names dcl-dev-alb \
  --query 'LoadBalancers[].{Name:LoadBalancerName,DNS:DNSName,State:State.Code}' \
  --output table


# Estado de targets
aws elbv2 describe-target-health \
  --target-group-arn <TARGET_GROUP_ARN> \
  --query 'TargetHealthDescriptions[].{Target:Target.Id,Port:Target.Port,State:TargetHealth.State,Reason:TargetHealth.Reason}' \
  --output table


# Capacidad del Auto Scaling Group
aws autoscaling describe-auto-scaling-groups \
  --auto-scaling-group-names dcl-dev-asg-web \
  --query
'AutoScalingGroups[].{Min:MinSize,Desired:DesiredCapacity,Max:MaxSize,Instances:Instances[].{Id:InstanceId,State:LifecycleState,
Health:HealthStatus}}' \
  --output json
```

5. Evidencias y criterios de aceptación

Comprobación	Resultado esperado
Endpoint	DNS del ALB responde por HTTP.
Distribución	Refresh muestra al menos dos Instance ID y presencia en ambas AZ.
Identidad	Cada página muestra Region, AZ, Instance ID, Private IP y Public IP si aplica.
Health inicial	Targets del ASG aparecen healthy.
Prueba A	Durante el reboot se observa el comportamiento del Target Group y del ALB. Si

Comprobación	Resultado esperado
	el target llega a unhealthy mientras existe otro target healthy, registre que el ALB deja de enviarle nuevas solicitudes. Si el target se recupera antes de alcanzar unhealthy, registre igualmente la transición observada sin forzar ese estado.
ASG en Prueba A	Se registra lo observado sin asumir de antemano si conserva o reemplaza la instancia.
Prueba B	Terminate de una instancia del ASG provoca pérdida de capacidad y posterior recuperación de desired = 2.
Reemplazo	La nueva instancia se registra y llega a healthy en el Target Group.

Evidencias mínimas:

- Captura o tabla con ALB DNS y estado.
- Dos respuestas HTTP diferentes mostrando identidad de instancia.
- Target Group antes, durante y después de Prueba A.
- Estado del ASG observado durante Prueba A, sin forzar una conclusión predeterminada.
- ASG antes y después de terminar una instancia en Prueba B.
- Nueva Instance ID healthy en el Target Group.

6. Costos y cleanup obligatorio

Los recursos de ALB y EC2 consumen presupuesto del Learner Lab. El cleanup debe conservar el baseline de red y eliminar la capacidad temporal/costosa.

Conservar

- dcl-dev-vpc (Default VPC reutilizada).
- dcl-dev-subnet-public-a / dcl-dev-subnet-public-b.
- dcl-dev-subnet-private-a / dcl-dev-subnet-private-b.
- dcl-dev-igw, dcl-dev-rt-public y dcl-dev-rt-private.

Eliminar al finalizar

- En dcl-dev-asg-web, cambie primero min = 0 y desired = 0; espere que las instancias gestionadas terminen. Luego elimine el Auto Scaling Group.
- Elimine dcl-dev-alb y espere a que desaparezca.
- Elimine dcl-dev-tg-web.
- Elimine dcl-dev-lt-web si no será reutilizado por una instrucción posterior.
- Elimine dcl-dev-sg-web cuando ya no tenga interfaces/instancias asociadas.
- Elimine dcl-dev-sg-alb cuando el ALB haya desaparecido y no existan referencias que lo bloqueen.
- Si alguna EC2 independiente heredada de S05 seguía existiendo, termínela; no debe quedar como capacidad paralela fuera del ASG.

- Verifique en EC2 que no queden instancias Running o Stopped del laboratorio y que no permanezca un ALB activo.

OJO TÉCNICO. No elimine VPC, subnets, Internet Gateway ni tablas de rutas. Son el baseline persistente preparado desde S05.

7. Cierre técnico

- ¿Qué responsabilidad cumple el ALB que antes recaía en el usuario que elegía una IP?
- ¿Qué determina que un target sea elegible para recibir nuevas solicitudes?
- ¿Por qué la Prueba A no equivale a la Prueba B?
- ¿Qué significa desired = 2 cuando una de las instancias desaparece?

Conexión: S06 implementa balanceo, salud y capacidad repetible. No se incorporan almacenamiento de S07, rediseño de networking de S08, bases de datos, mensajería, observabilidad completa, seguridad avanzada ni Terraform.

Fuentes oficiales AWS

- Application Load Balancers — Introduction
- Target groups for your Application Load Balancers
- Health checks for Application Load Balancer target groups
- Amazon EC2 Auto Scaling — Auto Scaling groups / health checks
- Attach an Elastic Load Balancing load balancer to your Auto Scaling group
- Launch templates for Amazon EC2 Auto Scaling
- Reboot your Amazon EC2 instance
- Status checks for Amazon EC2 instances
- Access instance metadata / IMDSv2