Guía breve de lecturas — Sesión 14
Rendimiento y FinOps
Computación en Nube · EAFIT · 13 de octubre de 2026

Objetivo. Relacionar demanda, capacidad, utilización, rendimiento y costo para decidir si Digital Café Luna necesita más capacidad, mejor dimensionamiento o eliminar desperdicio sin degradar la experiencia del usuario.

Carga esperada: 22–27 minutos para las dos lecturas prioritarias; 5–7 minutos adicionales para la complementaria opcional. No hay entrega independiente.

LECTURA PRIORITARIA 1

Rendimiento, capacidad y elasticidad — escalar con evidencia

Alcance: Solutions Architect's Handbook — Third Edition, capítulo 6, "Performance Considerations". Lea la apertura y "Design principles for high-performance architecture" (pp. 177–181), limitándose a latency, throughput y concurrency. Luego revise únicamente "Applying auto-scaling" (pp. 199–200) para conectar capacidad con cambios de demanda. Como contraste AWS, revise solo el resultado esperado de right-sizing y dynamic scaling en Well-Architected.

No leer: selección detallada de tecnologías de almacenamiento o bases de datos, edge computing, mobile performance, performance testing detallado, catálogos de instancias, Compute Optimizer como herramienta ni configuración paso a paso de scaling.

Propósito: distinguir demanda, capacidad, utilización y rendimiento, y comprender que aumentar capacidad solo es una respuesta válida cuando la evidencia muestra una restricción que el escalamiento puede aliviar.

Preguntas orientadoras:

- ¿Qué evidencia necesitaría antes de concluir que aumentar capacidad mejorará realmente el rendimiento?
- ¿Cómo distinguiría un problema de dimensionamiento de un cambio temporal de demanda que podría requerir elasticidad?

Tiempo estimado: 11–14 minutos.

Abrir: AWS Well-Architected — Configure and right-size compute resources

Abrir: AWS Well-Architected — Scale your compute resources dynamically

Referencia: Solutions Architect's Handbook — Third Edition, capítulo 6, pp. 177–181 y 199–200.

LECTURA PRIORITARIA 2

Costo como ciclo de decisión — presupuesto, demanda y optimización continua

Alcance: Solutions Architect's Handbook — Third Edition, capítulo 10, pp. 290–295. Lea "Design principles for cost optimization", "Planning the budget and forecast", "Managing demand and service catalogs", "Keeping track of expenditure" y "Continuous cost optimization". Deténgase antes de "Understanding techniques for cost optimization". Como apoyo AWS, revise únicamente "Expenditure and usage awareness" y la introducción de "Monitor cost and usage".

Propósito: comprender que presupuesto, seguimiento y optimización forman un ciclo continuo; el gasto debe interpretarse junto con demanda, utilización y valor, evitando optimizar solo por reducción de costo.

No leer: técnicas específicas de compra o pricing, Savings Plans, Reserved Instances, Cost Explorer como tutorial, herramientas de recomendación, carbono/sostenibilidad avanzada, automatización de optimización ni contenido posterior a p. 295.

Preguntas orientadoras:

- ¿Cómo distinguiría un aumento de gasto justificable por mayor valor de uno causado por capacidad ociosa o desperdicio?
- ¿Por qué dimensionar permanentemente para un pico atípico puede producir una lectura equivocada de costo y utilización?
- ¿Qué relación debería existir entre presupuesto, demanda observada y decisiones de optimización?

Tiempo estimado: 11–13 minutos.

Abrir: AWS Well-Architected — Expenditure and usage awareness

LECTURA COMPLEMENTARIA OPCIONAL

Atribución del gasto mediante tags — costo con contexto

Alcance: Solutions Architect's Handbook — Third Edition, capítulo 10, "Resource cost tagging" (pp. 301–302). Si mantiene la carga prevista, lea únicamente el inicio de "Monitoring cost usage and reports" (p. 302). Como contraste AWS, revise solo la idea de agregar información organizacional al costo y uso mediante un esquema consistente de tags.

Propósito: entender por qué conocer el costo total de una cuenta no equivale a saber qué workload, entorno, proyecto o responsable lo genera, y cómo la atribución fortalece decisiones de optimización.

Preguntas orientadoras:

- ¿Qué decisiones se vuelven imposibles o más débiles si los recursos no tienen un esquema de etiquetado consistente?
- ¿Qué categorías mínimas permitirían atribuir gasto de Digital Café Luna sin convertir el etiquetado en un fin por sí mismo?

Tiempo estimado: 5–7 minutos opcionales.

Abrir: AWS Well-Architected — Add organization information to cost and usage

Frontera de esta sesión. No avance hacia Terraform, Infrastructure as Code, automatización de despliegues, estrategia multicloud, vendor lock-in ni comparación detallada AWS/Azure/GCP: corresponden a S15. No repita en profundidad logs, métricas, alarmas ni dashboards; en S14 esas señales son evidencia para optimizar. Digital Café Luna: durante un pico, el workload muestra mayor utilización y latencia; fuera del pico, la utilización cae significativamente, pero la capacidad permanece constante. ¿Qué evidencia adicional pediría antes de proponer un cambio? No resuelva todavía el escenario.